

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский университет ИТМО»
(Университет ИТМО)

Факультет прикладной информатики
Образовательная программа Мобильные и сетевые технологии
Направление подготовки 09.03.03 Прикладная информатика

О Т Ч Е Т
по лабораторной работе № 1
по дисциплине «Автоматическая обработка текста»

Тема: «Один текст — разные представления»

Обучающийся: Дущенко Даниил Александрович, К3341

Преподаватель: Гусарова Наталия Федоровна

Санкт-Петербург
2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
1 Выполнение работы.....	4
1.1 Данные и предварительная проверка.....	4
1.2 Методика.....	4
1.3 Результаты девяти сравнений.....	6
1.4 Три несоответствия близости и смысла	7
ЗАКЛЮЧЕНИЕ	8
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	9

ВВЕДЕНИЕ

В этой работе я исследовал, какие свойства русскоязычного текста сохраняются при переходе к вычислительному представлению. Сходство векторов удобно для поиска похожих сообщений, но не тождественно совпадению смысла. Я сравнил четыре представления: поверхностные признаки, bag-of-words, TF-IDF и sentence embeddings. Эксперимент построен на контролируемых преобразованиях: перестановке, парафразе и изменении смыслообразующего элемента. Численные результаты сопоставляются с заранее сформулированными семантическими суждениями.

1 Выполнение работы

1.1 Данные и предварительная проверка

Я использовал 150 сообщений RuSentiment [1]. Основной репозиторий больше не распространяет корпус, поэтому данные получены из публичного форка `strawberrypie/rusentiment`. Ссылка, контрольная сумма исходного файла и процедура отбора сохранены. Выборка взята из обучающей части общей подготовки с `random_state=42`; оставлены `positive`, `negative` и `neutral`. Классы `speech` и `skip` исключены. Это трёхклассовый учебный срез, а не воспроизведение исходной пяти-классовой задачи статьи.

В выборке 82 нейтральных, 46 положительных и 22 отрицательных сообщения. Пропусков и повторяющихся текстов после подготовки нет. В полном исходном файле случайных сообщений обнаружено 74 дубликата; удаление выполнено до отбора. Средняя длина равна 69,81 символа, медиана — 40,5, максимум — 789. Для токенов `razdel` среднее составляет 14,47, медиана — 9, максимум — 154. Разница среднего и медианы отражает длинный правый хвост: небольшое число длинных сообщений заметно влияет на среднее.




Рисунок 1 — Распределение длин текстов

1.2 Методика

Поверхностное представление содержит число символов, токенов и предложений, восклицательных и вопросительных знаков, а также долю

заглавных букв среди букв. Такие признаки описывают форму сообщения и могут отражать эмоциональную подачу, но не указывают, о чём именно говорит автор. Например, два противоположных утверждения способны иметь почти одинаковую длину и пунктуацию. Все признаки сохранены построчно с исходными идентификаторами.

Для bag-of-words и TF-IDF я использовал CountVectorizer и TfidfVectorizer. Токенизация выполняется razdel, регистр понижается, чистая пунктуация исключается. Лемматизация и удаление стоп-слов не применяются: важно сохранить отрицание «не». Словарь и IDF обучаются только на 150 исходных текстах. Изменённые варианты преобразуются уже готовыми векторизаторами. Поэтому эксперимент также выявляет проблему неизвестных слов; доля OOV сохранена отдельно для каждой пары.

Плотное представление строится sentence-transformers с multilingual-e5-small [2]. Для симметричного сравнения обе стороны получают одинаковый префикс query:, векторы нормируются. Я вычислил эмбединги на CPU, поэтому запуск работы не требует свободной видеокарты. Размерность и параметры модели записаны в embedding_config.json. Для каждого преобразования я рассчитал косинусное сходство с оригиналом; всего получено девять пар. Поверхностные признаки не включены в косинусное сравнение: задание требует его для трёх остальных представлений.

Я выбрал оригиналы трёх классов: положительное сообщение о спокойной песне, отрицательное сообщение о глупых репостах и нейтральный вопрос о времени выезда. При конструировании преобразований я заранее сформулировал семантические решения и обоснования, чтобы затем сопоставить их с численным сходством. Для парафраза вопроса сохраняется основное содержание, хотя эмоциональный оттенок обращения немного ослабляется.

1.3 Результаты девяти сравнений

Таблица 1 — Результаты сравнения

Класс и преобразование	BoW	TF-IDF	E5
Positive: перестановка	1,000	1,000	0,990
Positive: парафраз	0,224	0,247	0,930
Positive: изменение смысла	0,913	0,974	0,974
Negative: перестановка	1,000	1,000	0,999
Negative: парафраз	0,000	0,000	0,904
Negative: изменение смысла	0,943	0,979	0,987
Neutral: перестановка	1,000	1,000	0,990
Neutral: парафраз	0,577	0,505	0,892
Neutral: изменение смысла	0,816	0,792	0,988




Рисунок 2 — Косинусное сходство девяти пар

Перестановка не меняет unigram-счётчики, поэтому обе разреженные модели возвращают ровно единицу. Этот результат следует из определения представления, а не доказывает языковое понимание. Эмбединги немного меняются, поскольку модель чувствительна к последовательности. Для

парафразов плотное представление существенно лучше сохраняет близость: значения 0,892–0,930 против 0–0,577 у разреженных методов. Однако часть падения BoW объясняется малым словарём и морфологическими различиями, а не только заменой смысла.

1.4 Три несоответствия близости и смысла

Первый случай: «Обожаю её» заменено на «Не обожаю её». Утверждение о восхищении отрицается, но TF-IDF даёт 0,974 и E5 — 0,974. Почти весь словарь и тема песни сохранены; частое короткое отрицание мало меняет направление вектора. При этом новая фраза не обязательно означает ненависть: корректный вывод ограничен отсутствием прежнего утверждения.

Второй случай: «у тебя одни глупые репосты» превращается в «у тебя не одни глупые репосты». Меняется область отрицания и всеобщность оценки: допускаются другие публикации. BoW остаётся равным 0,943, TF-IDF — 0,979, E5 — 0,987. Плотная модель в этой паре даже менее чувствительна, чем простое счётное представление. Тематическая близость не позволяет восстановить логический квантор.

Третий случай: «Когда выезжаешь» заменено на «Когда приезжаешь». Оба сообщения относятся к поездке, но запрашивают разные события и обычно разные моменты времени. E5 показывает 0,988 — больше, чем для смылсохраняющего парафраза этого же вопроса. Разреженные методы замечают замену слова сильнее, однако сами не объясняют различие выезда и прибытия. Следовательно, универсальный порог сходства не решает задачу эквивалентности.

ЗАКЛЮЧЕНИЕ

Поверхностные признаки сохраняют форму, BoW — лексический состав, TF-IDF — взвешенный лексический состав, E5 — более широкую тематическую и семантическую близость. Плотные векторы полезнее для перефразирования, но могут игнорировать отрицание и замену события. Девять специально выбранных пар иллюстрируют механизм ошибки, а не оценивают её частоту в языке. Для задач, где важны противоположные утверждения, после поиска похожих текстов необходима отдельная проверка содержания. Я последовательно выполнил notebook; исходные данные, преобразования, матрицы, графики и таблицы сохранены для повторного запуска.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

[1] Rogers A. et al. RuSentiment: An Enriched Sentiment Analysis Dataset for Social Media in Russian. COLING, 2018. URL: <https://aclanthology.org/C18-1064/> (дата обращения: 08.09.2026). Данные: <https://github.com/strawberrypie/rusentiment>.

[2] intfloat. Multilingual E5 small: model card. URL: <https://huggingface.co/intfloat/multilingual-e5-small> (дата обращения: 08.09.2026).