

**Министерство науки и высшего образования Российской Федерации**  
**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ**  
**«Национальный исследовательский университет ИТМО»**  
**(Университет ИТМО)**

**Факультет прикладной информатики**  
**Образовательная программа Мобильные и сетевые технологии**  
**Направление подготовки 09.03.03 Прикладная информатика**

**О Т Ч Е Т**  
**по лабораторной работе № 2**  
**по дисциплине «Автоматическая обработка текста»**

Тема: «Разметка неоднозначной категории»

Обучающиеся: Дущенко Даниил Александрович, К3341  
Коваленко Евгений Юрьевич, К3341

Преподаватель: Гусарова Наталия Федоровна

Санкт-Петербург  
2026

## СОДЕРЖАНИЕ

|                                                |   |
|------------------------------------------------|---|
| ВВЕДЕНИЕ.....                                  | 3 |
| 1 Выполнение работы .....                      | 4 |
| 1.1 Первичная разметка .....                   | 4 |
| 1.2 Выбор разногласий и общая инструкция ..... | 4 |
| 1.3 Три спорных примера.....                   | 5 |
| 1.4 Повторный этап и ограничения.....          | 6 |
| 1.5 Вклад участников.....                      | 7 |
| ЗАКЛЮЧЕНИЕ .....                               | 8 |
| СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ .....         | 9 |

## ВВЕДЕНИЕ

Цель работы — показать зависимость метки от определения категории и процедуры разметки. Выбрана срочность обращения. Мы сгенерировали 90 коротких синтетических русскоязычных сообщений без меток. В набор включены аварии, бытовые просьбы, рекламные призывы, обычные сроки, цитаты и отрицания. Содержание не извлечено из персональных переписок. Файл `texts.csv` сохраняет стабильные ID; эти же идентификаторы используются на обоих этапах.

Мы организовали эксперимент с тремя изолированными LLM-разметчиками А, В и С. Каждый получил исходные тексты и сначала сформулировал собственное рабочее определение. Чужие определения и метки до завершения первичного этапа не передавались. Далее мы сравнивали три сохранённых набора ответов. Это сравнение модельных разметок; коэффициенты не оценивают согласие двух авторов отчёта.

## 1 Выполнение работы

### 1.1 Первичная разметка

Разметчик А связывал срочность с обоснованной безотлагательностью: риском или коротким сроком с последствиями. В ориентировался на выраженное требование ускорения. С также учитывал коммуникативные признаки, но чаще оставлял неопределённость при неявном запросе и неизвестном сроке. Все 90 сообщений независимо получили 1, 0 или ?. Значение ? рассматривается как полноценная третья категория, а не пропуск. Первичные ответы и краткие основания сохранены без согласования и исправлений.

Мы вычислили три попарных Cohen's kappa и многопользовательская Fleiss' kappa через готовую функцию statsmodels [1, 2]. Использованы номинальные категории без весов: порядок 0, 1, ? не задаёт численного расстояния. Дополнительно рассчитана доля полного совпадения трёх ответов. Это помогает отличить непосредственно наблюдаемое согласие от коэффициента с поправкой на случайное совпадение.

Таблица 1 — Результаты сравнения

| Метрика         | Все 90, первично | Спорные 30, до | Те же 30, после |
|-----------------|------------------|----------------|-----------------|
| Cohen A/B       | 0,409            | −0,133         | 1,000           |
| Cohen A/C       | 0,528            | −0,071         | 1,000           |
| Cohen B/C       | 0,825            | 0,583          | 1,000           |
| Fleiss          | 0,570            | −0,004         | 1,000           |
| Полное согласие | 0,600            | 0,000          | 1,000           |

### 1.2 Выбор разногласий и общая инструкция

Степень разногласия определена как число несовпадающих пар среди трёх разметчиков. Мы отобрали 30 записей с максимальным значением; равенства разрешались по ID. Поэтому отбор воспроизводим и не зависит от желаемого результата повторной разметки. Сравнение до/после выполняется

на одних и тех же 30 объектах, а не между исходными 90 и более трудным подмножеством. Остальные 60 текстов повторно не размечались.

Мы объединили причины в пять групп: явное требование против обоснованной необходимости; рекламная срочность; срок и недостающий временной контекст; неявное обращение или зависимость работы от ответа; цитирование чужого требования. Группа записана для каждой строки в `disagreements.csv`. Существенная часть расхождений возникла не из-за невнимательности, а из-за разных объектов оценки: А оценивал фактическую безотлагательность, В и С — речевое требование ускорения.

Общая инструкция закрепляет второй объект: выраженную срочность обращения. Она включает определение, положительные и отрицательные критерии, восемь примеров и правила пограничных случаев. Явное «срочно» учитывается независимо от важности темы и рекламной природы сообщения. Обычное «сегодня» без дополнительных сигналов не считается срочностью. Отрицание имеет приоритет; историческая цитата сама по себе не создаёт актуального требования. Метка ? предназначена для конкретной неразрешимой неоднозначности, а не для любого отсутствия подробностей.

### **1.3 Три спорных примера**

T26: «Мне срочно нужен совет по выбору обоев». Первично А поставил ?, В и С — 1. Для А отсутствовала причина немедленного решения, разметчики В и С учитывали прямой маркер. После инструкции все поставили 1: размечается выраженное требование, а не доказанная важность ремонта. Этот конфликт устраняется выбором операционального определения, а не обнаружением скрытого объективного ответа.

T49: «До закрытия приёма заявок осталось полчаса». А выбрал 1, В и С — ?. Сигнал близкого срока очевиден, но прямой просьбы нет. Общая инструкция разрешила учитывать короткое закрывающееся окно как подразумеваемое обращение. Повторно получено 1/1/1. Решение зависит от

принятого правила о косвенных речевых актах; при другой постановке задачи допустима другая разметка.

T65: «Без подписи работа стоит». Первичные ответы — ?/1/?. Неизвестно, идёт ли речь о критическом процессе, обычной очереди согласования или пересказе. После инструкции получено ?/?/?. Согласованность выросла, но информационная неопределённость не исчезла. Участники лишь договорились одинаково её обозначать. Этот пример особенно важен: рост карра не всегда означает появление более определённого знания.

#### **1.4 Повторный этап и ограничения**

Каждый разметчик отдельно получил общую инструкцию и файл `disputed30.csv` без предыдущих столбцов. Все три повторных файла содержат одинаковые ответы, поэтому карра равна 1. Это фактический результат сохранённых разметок, а не целевое значение, под которое исправлялись метки. Однако инструкция разрабатывалась на этих же спорных примерах и включает близкие формулировки. Следовательно, результат показывает согласование на разобранном материале; для оценки переноса нужна новая слепая выборка.

Высокое согласие после уточнения критерия не доказывает валидность категории или её применимость к реальным экстренным обращениям. Одна модельная среда, синтетический корпус и повторное использование текстов могли облегчить согласование. Мы подготовили данные, организовали два этапа разметки, объединили ответы, рассчитали метрики и составили общую инструкцию. При анализе мы отдельно проверили влияние определения категории и недостатка контекста.

## 1.5 Вклад участников

Дущенко Даниил Александрович подготовил корпус из 90 сообщений и идентификаторы записей, организовал получение первичных и повторных модельных разметок, объединил файлы ответов и реализовал воспроизводимый выбор 30 спорных текстов.

Коваленко Евгений Юрьевич систематизировал причины разногласий, подготовил общую инструкцию и примеры пограничных случаев, выполнил расчёт и проверку коэффициентов Cohen's kappa и Fleiss' kappa, сопоставил результаты до и после уточнения инструкции.

Совместно мы сформулировали выводы и подготовили отчёт. Обозначения A/B/C относятся к трём модельным разметчикам, а не к авторам отчёта; их исходные ответы при анализе не исправлялись.

## **ЗАКЛЮЧЕНИЕ**

Инструкция устраняет расхождения, вызванные разными критериями, обработкой рекламы, сроков и цитат. Недостаток реального контекста полностью устранить нельзя: его следует явно кодировать и анализировать. Целевая переменная возникает из согласованной исследовательской процедуры. Для воспроизводимости сохранены шесть файлов индивидуальных ответов, объединённая таблица, список спорных случаев, инструкция и расчёт метрик. Повторный запуск `evaluate.py` восстанавливает все коэффициенты из исходных меток.



## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

[1] scikit-learn. cohen\_kappa\_score. URL: [https://scikit-learn.org/stable/modules/generated/sklearn.metrics.cohen\\_kappa\\_score.html](https://scikit-learn.org/stable/modules/generated/sklearn.metrics.cohen_kappa_score.html) (дата обращения: 08.09.2026).

[2] statsmodels. fleiss\_kappa. URL: [https://www.statsmodels.org/stable/generated/statsmodels.stats.inter\\_rater.fleiss\\_kappa.html](https://www.statsmodels.org/stable/generated/statsmodels.stats.inter_rater.fleiss_kappa.html) (дата обращения: 08.09.2026).