

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский университет ИТМО»
(Университет ИТМО)

Факультет прикладной информатики
Образовательная программа Мобильные и сетевые технологии
Направление подготовки 09.03.03 Прикладная информатика

О Т Ч Е Т
по лабораторной работе № 2
по дисциплине «Автоматическая обработка текста»

Тема: «Разметка неоднозначной категории»

Обучающиеся: Дущенко Даниил Александрович, К3341
Коваленко Евгений Юрьевич, К3341

Преподаватель: Гусарова Наталия Федоровна

Санкт-Петербург
2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
1 Выполнение работы	4
1.1 Первичная разметка	4
1.2 Выбор разногласий и общая инструкция	4
1.3 Три спорных примера.....	5
1.4 Повторный этап и ограничения.....	6
1.5 Вклад участников.....	7
ЗАКЛЮЧЕНИЕ	8
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	9

ВВЕДЕНИЕ

Цель работы — показать зависимость метки от определения категории и процедуры разметки. Выбрана срочность обращения. Мы сгенерировали 90 коротких синтетических русскоязычных сообщений без меток. В набор включены аварии, бытовые просьбы, рекламные призывы, обычные сроки, цитаты и отрицания. Содержание не извлечено из персональных переписок. Файл `texts.csv` сохраняет стабильные ID; эти же идентификаторы используются на обоих этапах.

Мы организовали эксперимент с тремя изолированными LLM-разметчиками А, В и С. Каждый получил исходные тексты и сначала сформулировал собственное рабочее определение. Чужие определения и метки до завершения первичного этапа не передавались. Далее мы сравнивали три сохранённых набора ответов. Это сравнение модельных разметок; коэффициенты не оценивают согласие двух авторов отчёта.

1 Выполнение работы

1.1 Первичная разметка

Разметчик А связывал срочность с обоснованной безотлагательностью: риском или коротким сроком с последствиями. В ориентировался на выраженное требование ускорения. С также учитывал коммуникативные признаки, но чаще оставлял неопределённость при неявном запросе и неизвестном сроке. Все 90 сообщений независимо получили 1, 0 или ?. Значение ? рассматривается как полноценная третья категория, а не пропуск. Первичные ответы и краткие основания сохранены без согласования и исправлений.

Мы вычислили три попарных Cohen's kappa и многопользовательская Fleiss' kappa через готовую функцию statsmodels [1, 2]. Использованы номинальные категории без весов: порядок 0, 1, ? не задаёт численного расстояния. Дополнительно рассчитана доля полного совпадения трёх ответов. Это помогает отличить непосредственно наблюдаемое согласие от коэффициента с поправкой на случайное совпадение.

Таблица 1 — Результаты сравнения

Метрика	Все 90, первично	Спорные 30, до	Те же 30, после
Cohen A/B	0,409	−0,133	1,000
Cohen A/C	0,528	−0,071	1,000
Cohen B/C	0,825	0,583	1,000
Fleiss	0,570	−0,004	1,000
Полное согласие	0,600	0,000	1,000

1.2 Выбор разногласий и общая инструкция

Степень разногласия определена как число несовпадающих пар среди трёх разметчиков. Мы отобрали 30 записей с максимальным значением; равенства разрешались по ID. Поэтому отбор воспроизводим и не зависит от желаемого результата повторной разметки. Сравнение до/после выполняется

на одних и тех же 30 объектах, а не между исходными 90 и более трудным подмножеством. Остальные 60 текстов повторно не размечались.

Мы объединили причины в пять групп: явное требование против обоснованной необходимости; рекламная срочность; срок и недостающий временной контекст; неявное обращение или зависимость работы от ответа; цитирование чужого требования. Группа записана для каждой строки в `disagreements.csv`. Существенная часть расхождений возникла не из-за невнимательности, а из-за разных объектов оценки: А оценивал фактическую безотлагательность, В и С — речевое требование ускорения.

Общая инструкция закрепляет второй объект: выраженную срочность обращения. Она включает определение, положительные и отрицательные критерии, восемь примеров и правила пограничных случаев. Явное «срочно» учитывается независимо от важности темы и рекламной природы сообщения. Обычное «сегодня» без дополнительных сигналов не считается срочностью. Отрицание имеет приоритет; историческая цитата сама по себе не создаёт актуального требования. Метка ? предназначена для конкретной неразрешимой неоднозначности, а не для любого отсутствия подробностей.

1.3 Три спорных примера

T26: «Мне срочно нужен совет по выбору обоев». Первично А поставил ?, В и С — 1. Для А отсутствовала причина немедленного решения, другие участники учитывали прямой маркер. После инструкции все поставили 1: размечается выраженное требование, а не доказанная важность ремонта. Этот конфликт устраняется выбором операционального определения, а не обнаружением скрытого объективного ответа.

T49: «До закрытия приёма заявок осталось полчаса». А выбрал 1, В и С — ?. Сигнал близкого срока очевиден, но прямой просьбы нет. Общая инструкция разрешила учитывать короткое закрывающееся окно как подразумеваемое обращение. Повторно получено 1/1/1. Решение зависит от

принятого правила о косвенных речевых актах; при другой постановке задачи допустима другая разметка.

T65: «Без подписи работа стоит». Первичные ответы — ?/1/?. Неизвестно, идёт ли речь о критическом процессе, обычной очереди согласования или пересказе. После инструкции получено ?/?/?. Согласованность выросла, но информационная неопределённость не исчезла. Участники лишь договорились одинаково её обозначать. Этот пример особенно важен: рост карра не всегда означает появление более определённого знания.

1.4 Повторный этап и ограничения

Каждый разметчик отдельно получил общую инструкцию и файл `disputed30.csv` без предыдущих столбцов. Все три повторных файла содержат одинаковые ответы, поэтому карра равна 1. Это фактический результат сохранённых разметок, а не целевое значение, под которое исправлялись метки. Однако инструкция разрабатывалась на этих же спорных примерах и включает близкие формулировки. Следовательно, результат показывает согласование на разобранном материале; для оценки переноса нужна новая слепая выборка.

Высокое согласие после уточнения критерия не доказывает валидность категории или её применимость к реальным экстренным обращениям. Одна модельная среда, синтетический корпус и повторное использование текстов могли облегчить согласование. Мы подготовили данные, организовали два этапа разметки, объединили ответы, рассчитали метрики и составили общую инструкцию. При анализе мы отдельно проверили влияние определения категории и недостатка контекста.

1.5 Вклад участников

Дущенко Даниил Александрович подготовил корпус из 90 сообщений и идентификаторы записей, организовал получение первичных и повторных модельных разметок, объединил файлы ответов и реализовал воспроизводимый выбор 30 спорных текстов.

Коваленко Евгений Юрьевич систематизировал причины разногласий, подготовил общую инструкцию и примеры пограничных случаев, выполнил расчёт и проверку коэффициентов Cohen's kappa и Fleiss' kappa, сопоставил результаты до и после уточнения инструкции.

Совместно мы сформулировали выводы и подготовили отчёт. Обозначения A/B/C относятся к трём модельным разметчикам, а не к авторам отчёта; их исходные ответы при анализе не исправлялись.

ЗАКЛЮЧЕНИЕ

Инструкция устраняет расхождения, вызванные разными критериями, обработкой рекламы, сроков и цитат. Недостаток реального контекста полностью устранить нельзя: его следует явно кодировать и анализировать. Целевая переменная возникает из согласованной исследовательской процедуры. Для воспроизводимости сохранены шесть файлов индивидуальных ответов, объединённая таблица, список спорных случаев, инструкция и расчёт метрик. Повторный запуск `evaluate.py` восстанавливает все коэффициенты из исходных меток.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

[1] scikit-learn. cohen_kappa_score. URL: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.cohen_kappa_score.html (дата обращения: 08.09.2026).

[2] statsmodels. fleiss_kappa. URL: https://www.statsmodels.org/stable/generated/statsmodels.stats.inter_rater.fleiss_kappa.html (дата обращения: 08.09.2026).