

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский университет ИТМО»
(Университет ИТМО)

Факультет прикладной информатики
Образовательная программа Мобильные и сетевые технологии
Направление подготовки 09.03.03 Прикладная информатика

О Т Ч Е Т
по лабораторной работе № 3
по дисциплине «Автоматическая обработка текста»

Тема: «Классика против LLM»

Обучающийся: Дущенко Даниил Александрович, К3341

Преподаватель: Гусарова Наталия Федоровна

Санкт-Петербург
2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
1 Задание	4
2 Ход работы.....	5
2.1 Этап подготовки данных	5
2.2 Задание 1 и 2. Baseline и классический классификатор	5
2.3 Задание 3 и 4. Zero-shot и few-shot	6
2.4 Задание 5 и 6. Качество, время и стоимость	7
2.5 Задание 7. Анализ пятнадцати случаев.....	9
2.6 Задание 8. Рекомендации по применению	12
ЗАКЛЮЧЕНИЕ	13
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	14

ВВЕДЕНИЕ

Я сравнил четыре режима классификации тональности: наиболее частый класс, TF-IDF с логистической регрессией, zero-shot и few-shot одной LLM. Помимо accuracy и macro F1 оцениваются устойчивость на специально усложненных текстах, время, число токенов и стоимость обработки.

1 Задание

1. Построить baseline наиболее частого класса.
2. Обучить TF-IDF с n-граммами 1–2 и LogisticRegression; изменять не более двух гиперпараметров на validation.
3. Реализовать zero-shot одной LLM с JSON-полем label.
4. Реализовать few-shot той же модели с шестью примерами, по два каждого класса.
5. Оценить четыре режима на test и синтетическом стресс-наборе.
6. Измерить время, входные и выходные токены, оценить стоимость обработки.
7. Разобрать 15 случаев: пять ошибок классики, пять LLM и пять расхождений.
8. Сформулировать рекомендации для массовой, сложной и локальной обработки.

2 Ход работы

2.1 Этап подготовки данных

Я использовал подготовленную версию RuSentiment: 3000 объектов train, 500 validation и 500 test. Сохранены исходные positive, negative, neutral; speech и skip исключены. Train/validation получены из исходной случайной части, test — из отдельного тестового файла. Дубликаты устранены, пересечения текстов между тремя частями автоматически проверены. Validation применяется для подбора, test не используется для обучения и выбора промптов. Ссылки, распределения и SHA256 находятся в data/provenance.json. В test 321 neutral, 121 positive, 58 negative, поэтому accuracy большинства может выглядеть высокой при низком macro F1.

Я сгенерировал с помощью LLM стресс-набор из 100 новых русскоязычных сообщений: по 20 с отрицанием, опечатками, иронией, цитированием и смешанной оценкой. Для генерации использовалась другая LLM, а не оцениваемая Ministral. Тексты, запрос и критерии gold сохранены в make_stress.py и stress_provenance.json; SHA256 зафиксирован до первого оценочного запроса. Gold определяется позицией автора: явный положительный итог — positive, отрицательный — negative, факт или чужая оценка без собственной — neutral. В смешанной оценке приоритет имеет общий вердикт. Ироническая подвыборка содержит 20 отрицательных сообщений, поэтому категории не сбалансированы по классам. Синтетические тексты и метки одного генератора ограничивают независимость этой проверки.

2.2 Задание 1 и 2. Baseline и классический классификатор

Baseline всегда выбирает наиболее частый класс train — neutral. Основной классический метод: Pipeline(TfidfVectorizer(word ngrams 1–2), LogisticRegression). Я изменял только один гиперпараметр C: 0.5, 1.0, 2.0; выбран C=2.0 по максимальному validation macro F1=0.500. При равенстве

выбирается первый кандидат; прочие настройки фиксированы, `random_state=42`. После просмотра `test` гиперпараметры не менялись.

2.3 Задание 3 и 4. Zero-shot и few-shot

LLM — локальная `mistralai/ministral-3-14b-reasoning` в LM Studio. Одинаковы `temperature=0`, `seed=42`, `max_tokens=64` и ограничение `JSON-schema`. Ответ имеет единственное поле `label`; Pydantic запрещает лишние поля и неизвестные классы. Невалидный ответ сохраняется как `invalid` и считается ошибкой, без скрытого исправления. Zero-shot не содержит примеров. Few-shot добавляет шесть исходных `train`-примеров, по два каждого класса; тест проверяет их происхождение и метки. Текст пользователя трактуется как данные. Название `reasoning` не означает, что в данном режиме строился длинный вывод: `constrained decoding` ограничивает ответ JSON, а наблюдаемые токены `reasoning` сохранены в `usage`.

Я выполнил 1200 основных запросов: 600 текстов $\times$ 2 промпта. Валидных ответов: 1200 из 1200. Исходные ответы, ID запросов, UTC-время, параметры и `usage` сохранены до анализа. Кэш позволяет продолжать прерванный запуск; итоговые метрики запрещены при неполном наборе. Семь `pytest`-проверок покрывают неизменность `stress`, отсутствие утечки между выборками, схему и происхождение `few-shot` примеров.

2.4 Задание 5 и 6. Качество, время и стоимость

Таблица 1 — Результаты сравнения

Набор	Метод	Accuracy	Macro F1
stress	majority	0.230	0.125
stress	tfidf_lr	0.360	0.338
stress	zero_shot	0.900	0.884
stress	few_shot	0.900	0.889
test	majority	0.642	0.261
test	tfidf_lr	0.696	0.543
test	zero_shot	0.516	0.514
test	few_shot	0.670	0.659

Таблица 2 — Результаты сравнения

Набор	Метод	Задержка, с	Токены вход/выход
stress	majority	2.786e-06	0 / 0
stress	tfidf_lr	0.000412643	0 / 0
stress	zero_shot	2.79014	16257 / 700
stress	few_shot	2.78824	40257 / 700
test	majority	2.928e-07	0 / 0
test	tfidf_lr	0.000414999	0 / 0
test	zero_shot	2.71683	86672 / 3500
test	few_shot	2.72322	206672 / 3500

Лидер по macro F1 на test — few_shot, на stress — few_shot. Эти ранжирования относятся только к данному прогону; доверительные интервалы и повторные seed не оценивались. Разрез по каждому типу стресс-текста сохранен в stress_category_metrics.csv. Для категорий с отсутствующими классами F1 вычислен по фиксированным трем меткам и поэтому не должен сравниваться напрямую с macro F1 сбалансированной выборки.

На основном test TF-IDF+LR имеет accuracy 0,696 против 0,670 у few-shot, но macro F1 ниже: 0,543 против 0,659. Следовательно, вывод о лучшем

методе зависит от равного учета классов, а не только общей доли верных ответов. Zero-shot на test уступает даже классическому методу по macro F1 (0,514), тогда как few-shot заметно улучшает результат той же модели. На синтетическом stress обе LLM достигают accuracy 0,900 против 0,360 у LR. Этот разрыв не следует обобщать на любую «сложную» речь: стресс-примеры короткие и специально сформулированы генератором с явными критериями, а реальные социальные посты содержат контекстные и размытые неоднозначности.

Классический метод измеряется отдельными вызовами predict для каждого текста. Основные HTTP-запросы LLM выполнялись с concurrency 2; столбец времени включает сетевой round trip и серверное планирование. В начале прогона сервер также кратко обслуживал восемь дополнительных запросов лабораторной 5, поэтому этот журнал отражает нагрузочный режим с коротким совместным использованием, а не контролируемую изолированную производительность. Это end-to-end latency, а не изолированное одиночное время генерации. Наблюдаемый общий throughput — 0.732 ответа/с. Отдельно я выполнил 20 последовательных запросов на первых 10 train текстах с двумя промптами: средняя end-to-end задержка 2.391 с, throughput 0.418 ответа/с. Эти ответы не входят в качество test/stress и не использованы для подбора.

Входные и выходные токены взяты из API usage, использующего родной токенизатор обслуживаемой Mistral-модели вместе с шаблоном чата. Дополнительно через lmstudio SDK 1.5.0 вызван tokenize у уже загруженной модели для десяти train-текстов; token IDs, количество и время сохранены в native_tokenizer.json. Эта отдельная проверка токенизирует сырой текст без шаблона чата, поэтому ее счетчики закономерно отличаются от prompt_tokens API. Подсчет по символам или токенизатором другой модели не подменяет измерение. Внешний тариф локальной LM Studio отсутствует: денежная стоимость API для 1000 текстов — 0 USD. Электричество,

амортизация и затраты времени пользователя не оценивались, поэтому «нулевая стоимость API» не означает бесплатную эксплуатацию.

2.5 Задание 7. Анализ пятнадцати случаев

Я выбрал случаи воспроизводимо: первые пять ошибок классики, первые пять ошибок few-shot LLM и первые пять расхождений, исключая уже выбранные ID. Эталоны RuSentiment не исправлялись после просмотра ответов. Объяснения описывают текст и наблюдаемые результаты; они не претендуют на доступ к внутренней причине решения модели.

1. Ошибка классики, test_01325. Короткое эмоциональное сообщение «Хах.Фагот!!!)))» имеет корпусную метку positive. TF-IDF+LR и few-shot отвечают neutral: стандартная токенизация теряет скобочные смайлы и пунктуационную экспрессию, а редкое слово без контекста малоинформативно. Это правдоподобное объяснение наблюдения, а не измеренная причинная атрибуция.

2. Ошибка классики, test_00360. В «Музыка моей молодости :D» положительная эмоция выражена ностальгией и смайлом. Классика возвращает neutral, few-shot — правильный positive. Для признаковой модели ностальгическая конструкция может не иметь достаточного веса; смайл по умолчанию не сохраняется как отдельный информативный токен.

3. Ошибка классики, test_00789. «Люди смеются, чтобы не заплакать» размечено negative. Оба метода дают neutral: буквальное присутствие смеха не отражает прагматическое неблагополучие. Фраза также похожа на цитатный афоризм, поэтому граница между авторской эмоцией и нейтральной передачей высказывания неоднозначна; исходный gold не менялся.

4. Ошибка классики, test_02750. Приглашение «а сегодня пойдем гулять????» имеет neutral. Оба метода предсказывают positive, приписывая положительный настрой факту приглашения и эмоциональной пунктуации.

Пример показывает, что разговорная экспрессия сама по себе не равна положительной оценке.

5. Ошибка классики, test_00602. Вопрос «А ты хайп?» размечен neutral. Классика выбирает positive, few-shot сохраняет neutral. Из короткого сленгового вопроса нельзя надежно вывести оценку автора; редкая лексика и отсутствие контекста делают ошибку признаковой модели понятной, но не позволяют доказать конкретную причину без анализа коэффициентов.

6. Ошибка LLM, test_02597. Пост о Гарри Поттере содержит «я в шоке от этих маркетологов» и ироничные детали. Корпусный gold — neutral, few-shot — negative, классика — neutral. Модель усилила критическую интерпретацию. Это реальное расхождение с эталоном, однако в нем есть субъективная пограничность разметки, а не бесспорная грамматическая ошибка.

7. Ошибка LLM, test_02633. Мотивирующие стихотворные строки о победе размечены neutral. Few-shot дает positive, приняв содержание процитированного текста за положительную позицию автора публикации. Классика совпадает с gold. Чтобы устранить такую ошибку, нужно отдельно определить статус цитат и репостов, не меняя инструкцию после просмотра test.

8. Ошибка LLM, test_01460. «Ужасно как я мечтаю о порядке у себя на кухне)))» имеет neutral; few-shot выбирает negative. Здесь «ужасно» выступает усилителем желания, а не однозначной отрицательной оценкой. Модель переоценила лексический маркер и недооценила функцию слова в конструкции.

9. Ошибка LLM, test_01198. «oooooooo тебя тоже поперла моя песенка????» имеет neutral. Оба метода дают positive, трактуя разговорную экспрессию как положительную эмоцию. Вопрос о чужой реакции не обязательно выражает собственную оценку; это ограничение выделения носителя тональности.

10. Ошибка LLM, test_00760. Рекламное сообщение с обещанием бесплатной футболки и эмодзи размечено neutral. Few-shot дает positive, реагируя на подарок и позитивную визуальную подачу. Классика сохраняет neutral. Привлекательность рекламного предложения не должна автоматически становиться эмоцией автора.

11. Расхождение, test_01758. В перечислении «Лучшие вещи в жизни — бесплатны» gold=positive. Классика предсказывает neutral, few-shot=positive. Явный маркер «лучшие» и список приятных явлений доступны обоим методам, но генеративная модель в этом случае лучше передает общий оценочный смысл.

12. Расхождение, test_00362. Междометие «Ееееее!!!)» имеет positive. TF-IDF+LR дает neutral, few-shot=positive. Почти вся информация заключена в удлинении буквы, восклицаниях и скобках; редкое междометие и стандартная токенизация затрудняют обобщение классики.

13. Расхождение, test_01008. Сообщение об Арнольде Шварценеггере с характеристикой «уникальный человек» имеет neutral. Классика совпадает с gold, few-shot дает positive, воспринимая необычные способности как похвалу. Случай демонстрирует возможную избыточную оценочность LLM относительно правил конкретного корпуса.

14. Расхождение, test_00873. Объявление о мастер-классе по изготовлению открыток размечено neutral. Классика дает neutral, few-shot=positive. Восклицательные знаки и скобочный смайл повысили кажущуюся эмоциональность, хотя основная функция сообщения — информирование о мероприятии.

15. Расхождение, test_00229. Короткое «Ты чегооо?..» имеет neutral. Классика дает positive, few-shot=neutral. Растяжение гласной обозначает экспрессию, но без контекста не устанавливает ее знак. В этом случае LLM верно воздерживается от приписывания положительной оценки.

2.6 Задание 8. Рекомендации по применению

Для массовой обработки разумно рассматривать TF-IDF+LR как быстрый воспроизводимый первый уровень и проверять, устраивает ли его измеренный F1. Baseline большинства полезен только как нижняя контрольная точка: он игнорирует содержание и плохо отражает редкие классы. Для небольшого потока сложных текстов LLM позволяет учитывать цитаты и прагматику, но реальные ошибки показывают склонность приписывать оценку рекламным и информационным сообщениям; автоматическую генерацию нельзя считать безошибочной разметкой. Выбор zero-shot или few-shot следует делать на отдельной validation-проверке, не по максимальному test-результату этой работы.

Для локальной обработки без внешнего API доступны оба подхода: классический метод имеет небольшие вычислительные требования, LLM требует достаточной памяти и большей задержки. Исследуемая конфигурация сохраняет тексты в локальном процессе LM Studio. Практический комбинированный маршрут — классика для обычного потока и LLM для отдельной проверки неоднозначных случаев — здесь не измерялся и остается предложением, а не доказанным улучшением.

ЗАКЛЮЧЕНИЕ

На test few-shot получил macro F1 0,659 против 0,543 у TF-IDF с логистической регрессией, однако классический метод дал более высокую accuracy: 0,696 против 0,670. На синтетическом stress оба LLM-режима достигли accuracy 0,900. Классический метод значительно быстрее; выбор решения зависит от требований к задержке и качества на разных классах. Few-shot улучшил результат относительно zero-shot на test, но преимущество не следует переносить на другие данные без проверки.

Ограничения: один train split, одна модель, один набор few-shot примеров, синтетический stress от одного генератора, отсутствие независимой разметки stress и неопределенность некоторых социальных постов. Выводы ограничены представленными 600 текстами и сохраненными измерениями.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. RuSentiment: русский корпус тональности. URL: <https://github.com/text-machine-lab/rusentiment> (дата обращения: 08.09.2026).
2. Доступная копия данных: <https://github.com/strawberrypie/rusentiment>. Точные URL и SHA256 — в `provenance.json`.
3. Синтетический стресс-набор: генерация с помощью LLM в данной работе, 08.09.2026; запрос и критерии — `stress_provenance.json`.