

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский университет ИТМО»
(Университет ИТМО)

Факультет прикладной информатики
Образовательная программа Мобильные и сетевые технологии
Направление подготовки 09.03.03 Прикладная информатика

О Т Ч Е Т
по лабораторной работе № 4
по дисциплине «Автоматическая обработка текста»

Тема: «Промпт как программа»

Обучающийся: Дущенко Даниил Александрович, К3341

Преподаватель: Гусарова Наталия Федоровна

Санкт-Петербург
2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
1 Задание	4
2 Ход работы.....	5
2.1 Этап подготовки данных и эталона.....	5
2.2 Задание 1 и 2. Две версии промпта	5
2.3 Задание 3–5. Схема, доказательства и повтор	6
2.4 Задание 6. Автоматические тесты	6
2.5 Задание 7. Сравнение версий.....	7
2.6 Этап анализа пяти ошибок	7
2.7 Дополнительная проверка эталона.....	9
ЗАКЛЮЧЕНИЕ	10
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	11

ВВЕДЕНИЕ

Цель — построить проверяемый интерфейс извлечения названий препаратов, показаний, положительных эффектов, нежелательных реакций и подтверждающих цитат. Проверяется не медицинская эффективность средств, а соответствие результата тексту отзыва. Система должна различать синтаксическую правильность JSON, соблюдение формальной схемы и фактическую обоснованность извлечений: эти свойства не равнозначны.

1 Задание

1. Подготовить простой промпт version_1 без примеров.
2. В version_2 уточнить поля, отрицания и добавить два размеченных примера.
3. Описать выходную схему через Pydantic и проверить структуру.
4. Проверять дословное присутствие каждого evidence в исходном тексте.
5. При невалидном ответе разрешить ровно один повтор с описанием ошибки.
6. Реализовать автоматические тесты для десяти обязательных случаев.
7. Сравнить версии по валидности, качеству извлечения и неподтверждённым результатам; разобрать пять ошибок.

2 Ход работы

2.1 Этап подготовки данных и эталона

Я использовал размеченную часть RuDReC: 500 отзывов, представленных построчно на уровне предложений [1]. Я объединил предложения по `file_name` в порядке `sentence_id`. В эксперимент вошли 50 самых коротких полных отзывов; при равной длине использован порядок идентификаторов. Это воспроизводимый экономичный отбор без случайного выбора удачных примеров, однако он смещает оценку к коротким сообщениям и не позволяет переносить результат на весь корпус.

Я взял эталон из Drugname, DI и ADR исходного корпуса и адаптировал его к полям задания. Положительные эффекты добавлены после чтения всех 50 текстов; гипотетические, процитированные и отрицаемые реакции обработаны согласно инструкции. Явные изменения зафиксированы в `prerepare.py`. Такая адаптация не является независимой экспертной или медицинской проверкой. Файл и его SHA256 сохранены до первого запроса; `runner` проверяет неизменность эталона. Эталон не исправлялся по ответам модели.

2.2 Задание 1 и 2. Две версии промпта

`version_1` содержит короткую инструкцию без примеров. `version_2` определяет каждое поле, требует сохранять написание названий, различать показания и реакции, не считать отрицание и ожидание достигнутым эффектом. Два размеченных примера демонстрируют опечатку, частичный результат, отрицание и чужую цитату. Наблюдение автора о ребенке допустимо как описание конкретного пациента; пересказ чужого отзыва не принимается за собственное наблюдение.

2.3 Задание 3–5. Схема, доказательства и повтор

Pydantic запрещает лишние поля, пропущенные поля и значения неверного типа. Каждый evidence должен быть непустой дословной подстрокой текста. version_2 дополнительно требует, чтобы каждое извлеченное значение входило в одну из подтверждающих цитат. После ошибки отправляется ровно один запрос с ее описанием. Если повтор также невалиден, результат отклоняется; третьего запроса нет. Исходные ответы и ошибки сохраняются, поэтому повтор можно проверить по журналу.

Использована одна локальная mistralai/ministral-3-14b-reasoning через LM Studio: temperature=0, seed=42, max_tokens=2048. В обеих версиях заранее включено одинаковое ограничение JSON-schema при декодировании. Поэтому сравнение валидности относится к системе с ограниченным декодированием, а не к свободной генерации; высокий результат по JSON сам по себе не доказывает преимущество расширенного промпта. Промпты не изменялись во время прогона.

2.4 Задание 6. Автоматические тесты

Выполнены 28 pytest-проверок, включая целостность gold, восстановление полных отзывов и восемь проверок сохраненных ответов настоящей LLM. Восемь обязательных содержательных случаев проверяют прием корректных контрактов на тестовом backend: пустой текст, отсутствие названия, несколько препаратов, отрицание, предположение, реакция у другого пациента, цитата, опечатка. Отдельные тесты проверяют лишнее поле, выдуманную цитату, строгие типы, регистр, пустую цитату, покрытие извлечений и остановку после одного повтора. Эти тесты не подменяют измерение способности LLM понимать текст. Дополнительно те же восемь содержательных ситуаций реально отправлены модели: пройдено 8 из 8 проверок; ответы находятся в behavioral.jsonl.

2.5 Задание 7. Сравнение версий

Качество — micro precision/recall/F1 по уникальным парам «поле, словесный токен» внутри каждого отзыва. Слова приводятся к нижнему регистру без лемматизации. Невалидный итог считается пустым извлечением. Метрика частично допускает разные границы фразы, но штрафует изменение окончаний и лишние пояснения; она не эквивалентна оценке медицинской корректности. Неподтвержденное значение в автоматическом счетчике — строка, не встречающаяся в тексте. Это поверхностный индикатор: корректный пересказ тоже может попасть в него, а ошибочная интерпретация настоящей цитаты — не попасть.

Таблица 1 — Результаты сравнения

Версия	JSON первого ответа	Контракт с первого раза	Итоговый контракт	Повторы	F1	Строки вне текста, итог
version_1	50/50	39/50	45/50	11	0.524	60
version_2	50/50	37/50	42/50	13	0.575	0

Таблица 2 — Результаты сравнения

Версия	Среднее время с повторами, с/отзыв	Входные токены	Выходные токены	Precision	Recall
version_1	6.62	12131	7385	0.496	0.555
version_2	7.65	46717	8587	0.535	0.622

Время — наблюдаемая задержка HTTP, включая повторные ответы, деленная на 50. Токены получены из usage сервера, а не оценены по длине строк. Поскольку модель локальная, счета внешнего API нет; энергопотребление и амортизация видеокарты не измерялись.

2.6 Этап анализа пяти ошибок

1. 3004353.tsv, version_1. Вместо названия средства извлечено «таблетки», хотя название отсутствует. В evidence есть настоящее предложение, но оно не подтверждает конкретное имя препарата. Это

семантическая ошибка типизации, которую одной проверкой подстроки устранить нельзя. Кроме того, модель заменила «мерзнуть пальцы» на «мерзнут пальцы»: смысл близок, но буквальная проверка фиксирует отсутствие такой строки.

2. 207209.tsv, version_1. Ответ содержит drug=[«препарат»], adverse_reaction=[«рвота», «тошнота»] вместо исходного «воротило и рвало». Отрицание положительного результата обработано верно. Ошибка в общем названии и нормализации показывает, почему извлечение необходимо отличать от пересказа: JSON валиден, цитата подлинная, однако строки сущностей изменены. Расширенная инструкция запрещает такие преобразования.

3. 807762.tsv, version_1. Пропущена нежелательная реакция — повышение температуры у ребенка после приема неназванного средства. Модель сохранила только сравнение с инфлюцидом и его положительный эффект. Наличие одного известного названия, вероятно, сузило извлечение до этого препарата; это интерпретация наблюдаемого ответа, а не установленная внутренняя причина. Правило должно разрешать фиксацию реакции и при неизвестном названии виновного средства.

4. 2491980.tsv, version_1. Ухудшение «стало только хуже» отнесено к adverse_reaction, хотя отзыв сообщает неэффективность лечения апатии и депрессии и не называет отдельную реакцию. Эталон оставляет это поле пустым. Кроме того, «апатии» и «депрессии» нормализованы в начальную форму. Это одновременно пограничная семантическая классификация и ограничение выбранной поверхностной метрики: не все штрафные токены означают грубую потерю смысла.

5. 2503806.tsv, version_2. «литическую смесь» модель включила в drug наряду с димедролом; эталон содержит только размеченное конкретное название. Цитата существует и проверку проходит, но многокомпонентная смесь не совпадает с принятой в эталоне категорией именованных препаратов. Дополнительно более длинное извлечение «Хороший препарат

быстро сбивает температуру.» снижает precision относительно короткого gold. Пример показывает зависимость оценки от гранулярности эталона и необходимость уточнять категорию до эксперимента.

2.7 Дополнительная проверка эталона

После основного эксперимента при дополнительной проверке я обнаружил три ошибки переноса NER-разметки в новую схему. В 1037212.tsv «спокойной» является результатом, а не показанием; в 2500038.tsv заболевания описаны как последующий итог курса, а не исходная причина назначения; в 895731.tsv «фуфломицин» — оценочное обозначение, а не имя препарата. Эти значения удалены только в отдельном data/gold_reviewed.jsonl; остальные поля не дополнены новыми интерпретациями. Исходный замороженный эталон и основные метрики выше сохранены. Подробные текстовые основания — data/gold_review_audit.md.

Те же 100 сохранённых ответов повторно оценены без новых запросов LLM. Исправления сформулированы по текстам и инструкции; рост метрики не был критерием их выбора. Это post-hoc проверка чувствительности, а не независимый новый тест и не полная экспертная ревизия gold.

Таблица 3 — Результаты сравнения

Версия	Исходный F1	F1 после трёх исправлений	Изменение F1	Precision нового gold	Recall нового gold
version_1	0,523810	0,526035	+0,002225	0,493734	0,562857
version_2	0,575130	0,572549	−0,002581	0,527711	0,625714

Изменения малы и разнонаправленны; вывод о более высоком F1 version_2 сохраняется. Однако аудит показывает, почему достоверность эталона нужно обсуждать отдельно от качества формального валидатора. Результаты и хеши опубликованы в results/sensitivity.json и results/sensitivity.csv; исходные предсказания не изменялись.

ЗАКЛЮЧЕНИЕ

В моём прогоне F1 вырос с 0,524 до 0,575, а число строк извлечений, отсутствующих в тексте, снизилось с 60 до 0. При этом итоговую валидацию прошли 45 из 50 ответов version_1 и 42 из 50 ответов version_2: более строгий контроль увеличил число отклонений. Среднее время выросло с 6,62 до 7,65 с на отзыв. Программная оболочка обеспечивает воспроизводимый формат, видимый механизм исправления и контроль дословности. Полная формальная валидность не гарантирует правильного распределения информации между полями. У version_2 доля строк вне исходного текста контролируется конструктивно, но проверка evidence не доказывает причинность и не исключает неверной классификации настоящего фрагмента. Сравнивать версии следует одновременно по F1, повторам, времени и анализу примеров. Эффект инструкции в этом исследовании ограничен одной моделью, одним прогоном, смещенной выборкой коротких отзывов и адаптированным эталоном; независимая экспертная оценка остается необходимой для практического применения.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Tutubalina E. et al. The Russian Drug Reaction Corpus and Neural Models for Drug Reactions and Effectiveness Detection in User Reviews // Bioinformatics. 2020. DOI: 10.1093/bioinformatics/btaa675. URL: <https://github.com/cimm-kzn/RuDReC> (дата обращения: 08.09.2026).

2. Pydantic: документация и установленная реализация Pydantic 2; pytest: автоматические тесты проекта. Версии зависимостей фиксируются общим файлом окружения репозитория.

README RuDReC называет корпус freely available; отдельная стандартная лицензия в корне источника не обнаружена. Данные не объявляются имеющими лицензию MIT или CC без подтверждения.