

**Министерство науки и высшего образования Российской Федерации**  
**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ**  
**«Национальный исследовательский университет ИТМО»**  
**(Университет ИТМО)**

**Факультет прикладной информатики**  
**Образовательная программа Мобильные и сетевые технологии**  
**Направление подготовки 09.03.03 Прикладная информатика**

**О Т Ч Е Т**  
**по лабораторной работе № 4**  
**по дисциплине «Автоматическая обработка текста»**

Тема: «Промпт как программа»

Обучающийся: Дущенко Даниил Александрович, К3341

Преподаватель: Гусарова Наталия Федоровна

Санкт-Петербург  
2026

## СОДЕРЖАНИЕ

|                                                   |    |
|---------------------------------------------------|----|
| ВВЕДЕНИЕ.....                                     | 3  |
| 1 Выполнение работы .....                         | 4  |
| 1.1 Данные и эталон .....                         | 4  |
| 1.2 Реализация .....                              | 4  |
| 1.3 Проверка и метрики .....                      | 5  |
| 1.4 Анализ пяти ошибок .....                      | 6  |
| 1.5 Чувствительность к исправлениям эталона ..... | 7  |
| ЗАКЛЮЧЕНИЕ .....                                  | 9  |
| СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ .....            | 10 |

## **ВВЕДЕНИЕ**

Цель — построить проверяемый интерфейс извлечения названий препаратов, показаний, положительных эффектов, нежелательных реакций и подтверждающих цитат. Проверяется не медицинская эффективность средств, а соответствие результата тексту отзыва. Система должна различать синтаксическую правильность JSON, соблюдение формальной схемы и фактическую обоснованность извлечений: эти свойства не равнозначны.

## **1 Выполнение работы**

### **1.1 Данные и эталон**

Я использовал размеченную часть RuDReC: 500 отзывов, представленных построчно на уровне предложений [1]. Я объединил предложения по `file_name` в порядке `sentence_id`. В эксперимент вошли 50 самых коротких полных отзывов; при равной длине использован порядок идентификаторов. Это воспроизводимый экономичный отбор без случайного выбора удачных примеров, однако он смещает оценку к коротким сообщениям и не позволяет переносить результат на весь корпус.

Я взял эталон из Drugname, DI и ADR исходного корпуса и адаптировал его к полям задания. Положительные эффекты добавлены после чтения всех 50 текстов; гипотетические, процитированные и отрицаемые реакции обработаны согласно инструкции. Явные изменения зафиксированы в `prerepare.py`. Такая адаптация не является независимой экспертной или медицинской проверкой. Файл и его SHA256 сохранены до первого запроса; `runner` проверяет неизменность эталона. Эталон не исправлялся по ответам модели.

### **1.2 Реализация**

`version_1` содержит короткую инструкцию без примеров. `version_2` определяет каждое поле, требует сохранять написание названий, различать показания и реакции, не считать отрицание и ожидание достигнутым эффектом. Два размеченных примера демонстрируют опечатку, частичный результат, отрицание и чужую цитату. Наблюдение автора о ребенке допустимо как описание конкретного пациента; пересказ чужого отзыва не принимается за собственное наблюдение.

`Pydantic` запрещает лишние поля, пропущенные поля и значения неверного типа. Каждый `evidence` должен быть непустой дословной подстрокой текста. `version_2` дополнительно требует, чтобы каждое

извлеченное значение входило в одну из подтверждающих цитат. После ошибки отправляется ровно один запрос с ее описанием. Если повтор также невалиден, результат отклоняется; третьего запроса нет. Исходные ответы и ошибки сохраняются, поэтому повтор можно проверить по журналу.

Использована одна локальная `mistralai/ministral-3-14b-reasoning` через LM Studio: `temperature=0`, `seed=42`, `max_tokens=2048`. В обеих версиях заранее включено одинаковое ограничение JSON-schema при декодировании. Поэтому сравнение валидности относится к системе с ограниченным декодированием, а не к свободной генерации; высокий результат по JSON сам по себе не доказывает преимущество расширенного промпта. Промпты не изменялись во время прогона.

### 1.3 Проверка и метрики

Выполнены 28 `pytest`-проверок, включая целостность `gold`, восстановление полных отзывов и восемь проверок сохраненных ответов настоящей LLM. Восемь обязательных содержательных случаев проверяют прием корректных контрактов на тестовом `backend`: пустой текст, отсутствие названия, несколько препаратов, отрицание, предположение, реакция у другого пациента, цитата, опечатка. Отдельные тесты проверяют лишнее поле, выдуманную цитату, строгие типы, регистр, пустую цитату, покрытие извлечений и остановку после одного повтора. Эти тесты не подменяют измерение способности LLM понимать текст. Дополнительно те же восемь содержательных ситуаций реально отправлены модели: пройдено 8 из 8 проверок; ответы находятся в `behavioral.jsonl`.

Качество — `micro precision/recall/F1` по уникальным парам «поле, словесный токен» внутри каждого отзыва. Слова приводятся к нижнему регистру без лемматизации. Невалидный итог считается пустым извлечением. Метрика частично допускает разные границы фразы, но штрафует изменение окончаний и лишние пояснения; она не эквивалентна оценке медицинской корректности. Неподтвержденное значение в

автоматическом счетчике — строка, не встречающаяся в тексте. Это поверхностный индикатор: корректный пересказ тоже может попасть в него, а ошибочная интерпретация настоящей цитаты — не попасть.

Таблица 1 — Результаты сравнения

| Версия    | JSON первого ответа | Контракт с первого раза | Итоговый контракт | Повторы | F1    | Строки вне текста, итог |
|-----------|---------------------|-------------------------|-------------------|---------|-------|-------------------------|
| version_1 | 50/50               | 39/50                   | 45/50             | 11      | 0.524 | 60                      |
| version_2 | 50/50               | 37/50                   | 42/50             | 13      | 0.575 | 0                       |

Таблица 2 — Результаты сравнения

| Версия    | Среднее время с повторами, с/отзыв | Входные токены | Выходные токены | Precision | Recall |
|-----------|------------------------------------|----------------|-----------------|-----------|--------|
| version_1 | 6.62                               | 12131          | 7385            | 0.496     | 0.555  |
| version_2 | 7.65                               | 46717          | 8587            | 0.535     | 0.622  |

Время — наблюдаемая задержка HTTP, включая повторные ответы, деленная на 50. Токены получены из usage сервера, а не оценены по длине строк. Поскольку модель локальная, счета внешнего API нет; энергопотребление и амортизация видеокарты не измерялись.

## 1.4 Анализ пяти ошибок

1. 3004353.tsv, version\_1. Вместо названия средства извлечено «таблетки», хотя название отсутствует. В evidence есть настоящее предложение, но оно не подтверждает конкретное имя препарата. Это семантическая ошибка типизации, которую одной проверкой подстроки устранить нельзя. Кроме того, модель заменила «мерзнуть пальцы» на «мерзнут пальцы»: смысл близок, но буквальная проверка фиксирует отсутствие такой строки.

2. 207209.tsv, version\_1. Ответ содержит drug=[«препарат»], adverse\_reaction=[«рвота», «тошнота»] вместо исходного «воротило и рвало». Отрицание положительного результата обработано верно. Ошибка в общем

названии и нормализации показывает, почему извлечение необходимо отличать от пересказа: JSON валиден, цитата подлинная, однако строки сущностей изменены. Расширенная инструкция запрещает такие преобразования.

3. 807762.tsv, version\_1. Пропущена нежелательная реакция — повышение температуры у ребенка после приема неназванного средства. Модель сохранила только сравнение с инфлюцидом и его положительный эффект. Наличие одного известного названия, вероятно, сузило извлечение до этого препарата; это интерпретация наблюдаемого ответа, а не установленная внутренняя причина. Правило должно разрешать фиксацию реакции и при неизвестном названии виновного средства.

4. 2491980.tsv, version\_1. Ухудшение «стало только хуже» отнесено к `adverse_reaction`, хотя отзыв сообщает неэффективность лечения апатии и депрессии и не называет отдельную реакцию. Эталон оставляет это поле пустым. Кроме того, «апатии» и «депрессии» нормализованы в начальную форму. Это одновременно пограничная семантическая классификация и ограничение выбранной поверхностной метрики: не все штрафные токены означают грубую потерю смысла.

5. 2503806.tsv, version\_2. «литическую смесь» модель включила в `drug` наряду с димедролом; эталон содержит только размеченное конкретное название. Цитата существует и проверку проходит, но многокомпонентная смесь не совпадает с принятой в эталоне категорией именованных препаратов. Дополнительно более длинное извлечение «Хороший препарат быстро сбивает температуру.» снижает `precision` относительно короткого `gold`. Пример показывает зависимость оценки от гранулярности эталона и необходимость уточнять категорию до эксперимента.

### **1.5 Чувствительность к исправлениям эталона**

После основного эксперимента при дополнительной проверке я обнаружил три ошибки переноса NER-разметки в новую схему. В 1037212.tsv

«спокойной» является результатом, а не показанием; в 2500038.tsv заболевания описаны как последующий итог курса, а не исходная причина назначения; в 895731.tsv «фуфломицин» — оценочное обозначение, а не имя препарата. Эти значения удалены только в отдельном data/gold\_reviewed.jsonl; остальные поля не дополнены новыми интерпретациями. Исходный замороженный эталон и основные метрики выше сохранены. Подробные текстовые основания — data/gold\_review\_audit.md.

Те же 100 сохранённых ответов повторно оценены без новых запросов LLM. Исправления сформулированы по текстам и инструкции; рост метрики не был критерием их выбора. Это post-hoc проверка чувствительности, а не независимый новый тест и не полная экспертная ревизия gold.

Таблица 3 — Результаты сравнения

| Версия    | Исходный F1 | F1 после трёх исправлений | Изменение F1 | Precision нового gold | Recall нового gold |
|-----------|-------------|---------------------------|--------------|-----------------------|--------------------|
| version_1 | 0,523810    | 0,526035                  | +0,002225    | 0,493734              | 0,562857           |
| version_2 | 0,575130    | 0,572549                  | −0,002581    | 0,527711              | 0,625714           |

Изменения малы и разнонаправленны; вывод о более высоком F1 version\_2 сохраняется. Однако аудит показывает, почему достоверность эталона нужно обсуждать отдельно от качества формального валидатора. Результаты и хеши опубликованы в results/sensitivity.json и results/sensitivity.csv; исходные предсказания не изменялись.

## ЗАКЛЮЧЕНИЕ

В моём прогоне F1 вырос с 0,524 до 0,575, а число строк извлечений, отсутствующих в тексте, снизилось с 60 до 0. При этом итоговую валидацию прошли 45 из 50 ответов version\_1 и 42 из 50 ответов version\_2: более строгий контроль увеличил число отклонений. Среднее время выросло с 6,62 до 7,65 с на отзыв. Программная оболочка обеспечивает воспроизводимый формат, видимый механизм исправления и контроль дословности. Полная формальная валидность не гарантирует правильного распределения информации между полями. У version\_2 доля строк вне исходного текста контролируется конструктивно, но проверка evidence не доказывает причинность и не исключает неверной классификации настоящего фрагмента. Сравнивать версии следует одновременно по F1, повторам, времени и анализу примеров. Эффект инструкции в этом исследовании ограничен одной моделью, одним прогоном, смещенной выборкой коротких отзывов и адаптированным эталоном; независимая экспертная оценка остается необходимой для практического применения.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Tutubalina E. et al. The Russian Drug Reaction Corpus and Neural Models for Drug Reactions and Effectiveness Detection in User Reviews // Bioinformatics. 2020. DOI: 10.1093/bioinformatics/btaa675. URL: <https://github.com/cimm-kzn/RuDReC> (дата обращения: 08.09.2026).

2. Pydantic: документация и установленная реализация Pydantic 2; pytest: автоматические тесты проекта. Версии зависимостей фиксируются общим файлом окружения репозитория.

README RuDReC называет корпус freely available; отдельная стандартная лицензия в корне источника не обнаружена. Данные не объявляются имеющими лицензию MIT или CC без подтверждения.