

**Министерство науки и высшего образования Российской Федерации**  
**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ**  
**«Национальный исследовательский университет ИТМО»**  
**(Университет ИТМО)**

**Факультет прикладной информатики**  
**Образовательная программа Мобильные и сетевые технологии**  
**Направление подготовки 09.03.03 Прикладная информатика**

**О Т Ч Е Т**  
**по лабораторной работе № 5**  
**по дисциплине «Автоматическая обработка текста»**

Тема: «Мини-RAG с доказательствами»

Обучающийся: Дущенко Даниил Александрович, К3341

Преподаватель: Гусарова Наталия Федоровна

Санкт-Петербург  
2026

## СОДЕРЖАНИЕ

|                                             |    |
|---------------------------------------------|----|
| ВВЕДЕНИЕ.....                               | 3  |
| 1 Выполнение работы.....                    | 4  |
| 1.1 Данные и организация эксперимента ..... | 4  |
| 1.2 Реализация .....                        | 4  |
| 1.3 Поиск до подключения LLM .....          | 5  |
| 1.4 Метрики и проверка.....                 | 5  |
| 1.5 Вклад участников.....                   | 6  |
| 1.6 Ограничения .....                       | 6  |
| 1.7 Результаты двух режимов .....           | 6  |
| 1.8 Анализ ошибок.....                      | 7  |
| 1.9 Пятнадцать разобранных ошибок .....     | 9  |
| ЗАКЛЮЧЕНИЕ .....                            | 11 |
| СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ .....      | 12 |

## **ВВЕДЕНИЕ**

Разделить ошибки поиска контекста и ошибки генерации ответа, сравнив полный документ с BM25 top-5 на одной локальной языковой модели. Отдельно проверить ссылки на доказательства и способность отказываться от ответа при недостатке сведений.

## **1 Выполнение работы**

### **1.1 Данные и организация эксперимента**

Программно создано 30 полностью вымышленных регламентов архивов по 24 абзаца. Каждый абзац имеет стабильный целочисленный идентификатор внутри документа. Корпус содержит 100 уникальных пар «документ–вопрос»; 30 вопросов не имеют ответа. Учебная часть включает 60 вопросов, тестовая — 40. Документы учебной и тестовой частей не пересекаются. Повторяются схемы вопросов, поэтому тест проверяет перенос извлечения на новые значения и документы, а не на принципиально новые типы запросов.

Вопросы охватывают должностных лиц, сроки, действия при аварии, отменённые нормы, контакты и отсутствующие сведения. Десять вопросов требуют объединить шесть разрешений из шести самостоятельных абзацев. Это намеренно трудный случай для ограничения top-5, а не случайная ошибка индекса. Эталон ответа создавался одновременно с фактами по детерминированным правилам и не выводился из предсказаний модели.

Учебные эталоны сохранены в `data/train.jsonl`. Публичная тестовая часть не содержит ответов; файл `evaluation_private/test_gold.jsonl` читает только оценщик. Генератор использует исключительно документы и вопросы. До вызовов сохранён манифест SHA-256; параметры и промпт после фиксации не подбираются по тесту. Это процедурное разделение в одном учебном репозитории: автор имеет доступ к закрытым эталонам, поэтому речь не идёт о независимом внешнем экзаменационном наборе.

### **1.2 Реализация**

Сегментация задана при генерации документов. Для ранжирования используется BM25, относящийся к вероятностным моделям информационного поиска [1]. BM25Okapi строится отдельно для документа из вопроса; токенизация выполняется `razdel`, регистр снижается,

лемматизация не применяется. При равных оценках сохраняется исходный порядок абзацев. Режим full получает все 24 абзаца, режим bm25 — ровно пять. Одна и та же модель и один системный промпт требуют ответ только по переданному контексту, допускают отказ и запрещают ссылки на отсутствующие абзацы.

Pydantic проверяет строгие типы без автоматического приведения значений [2]; схема также запрещает лишние поля. Положительный ответ требует непустого текста и evidence\_ids; отказ требует null и пустого списка. Повторяющиеся и несуществующие идентификаторы отклоняются. Ответы не ремонтируются и повторные запросы не используются. Сырые ответы, признак валидности, параметры, токены и время каждого запроса сохраняются до анализа.

### **1.3 Поиск до подключения LLM**

Macro recall доказательных абзацев в top-5 равен 0,97619 отдельно на учебной и тестовой частях. Вопросы без ответа исключены из знаменателя recall, поскольку у них нет доказательных абзацев. На 60 однофактных вопросах recall равен 1; на 10 шестичастных — 5/6. Полнота набора доказательств составляет  $60/70 = 0,85714$ . Высокий усреднённый recall поэтому не означает достаточности контекста для каждого ответа. Для шестичастного запроса ни настройка токенизатора, ни улучшение ранжирования не позволяют поместить шесть абзацев в top-5.

### **1.4 Метрики и проверка**

Качество ответа оценивается по наличию всех нормализованных эталонных значений с границами токенов; дополнительно публикуется exact match. Для имён, чисел и адресов это воспроизводимое приближение, но оно не заменяет полноценную семантическую оценку. Ссылки оцениваются precision, recall и F1 относительно эталонных абзацев. Для двух пустых списков все три метрики равны 1, поэтому отказы увеличивают общую

среднюю оценку evidence. Решение answerable оценивается относительно полного исходного документа, а не усечённого retrieval-контекста.

Автоматические проверки охватывают размеры корпуса, уникальность вопросов, разделение документов, отсутствие тестовых ответов в публичном файле, строгую схему, отказ, несуществующие ссылки и предел top-5. Восемь тестов прошли. Предварительные результаты поиска сохранены до генерации.

### **1.5 Вклад участников**

Работа подготовлена ИИ-ассистентом для одного студента. Моделируемая роль 1 отвечает за документы, сегментацию и индекс; роль 2 — за промпт, вызовы и валидацию; роль 3 — за метрики и анализ. Реальной группы из трёх людей и независимой человеческой проверки не было. Разделение обозначает ответственность компонентов, исходники которых необходимо понимать целиком при защите.

### **1.6 Ограничения**

Шаблонный синтетический корпус делает извлечение коротких фактов проще, чем в реальных документах. Целевая ошибка top-5 известна из конструкции данных. Локальная модель не тарифицируется по токенам; это не означает нулевые затраты на оборудование и электричество. Выводы ограничиваются данным набором и конфигурацией.

### **1.7 Результаты двух режимов**

Выполнены все 200 запросов: 100 вопросов в каждом режиме. Модель — mistralai/ministral-3-14b-reasoning, локальный LM Studio, temperature=0, seed=42, max\_tokens=700, строгий JSON Schema. Передача схемы через endpoint /v1/chat/completions соответствует официальному интерфейсу structured output LM Studio [3]. В наблюдаемом usage reasoning\_tokens равен

нулю. Стоимость внешнего API отсутствует; энергопотребление не измерялось.

Таблица 1 — Результаты сравнения

| Часть / режим | N  | Верные полные ответы | JSON валиден | Evidence F1 | Время, с | Вход, токены | Выход, токены |
|---------------|----|----------------------|--------------|-------------|----------|--------------|---------------|
| Train / full  | 60 | 1,000                | 1,000        | 1,000       | 3,176    | 1062,43      | 24,45         |
| Train / BM25  | 60 | 0,900                | 1,000        | 0,991       | 2,844    | 390,40       | 25,00         |
| Test / full   | 40 | 1,000                | 1,000        | 1,000       | 3,170    | 1063,00      | 25,15         |
| Test / BM25   | 40 | 0,900                | 1,000        | 0,991       | 2,829    | 390,50       | 24,90         |

На test BM25 уменьшил среднее число входных токенов на 63,26%, а время — на 10,75%. Экономия времени не пропорциональна экономии входа: генерация и постоянные расходы запроса остаются. Exact match равен 0,675 для full и 0,575 для BM25: расхождения с метрикой полноты преимущественно вызваны добавлением слов вроде «страниц», а не неверным фактом. Нельзя интерпретировать низкий exact match как столько же смысловых ошибок.

Все 30 вопросов, не имеющих ответа в полном документе, привели к отказам обоих режимов. Однако answerable имеет две разные интерпретации. По полному документу оба режима распознают его без ошибок. По фактически переданному контексту BM25 ошибается на десяти шестичастных вопросах: отвечает true и перечисляет только пять разрешений. Поэтому дополнительная context\_answerable\_accuracy равна 0,90 против 1,00 у full. Oracle доступного контекста здесь требует всех эталонных посылок; для данного корпуса альтернативных доказательств нет.

## 1.8 Анализ ошибок

В results/error\_analysis.md отдельно разобраны пять потерь retrieval (Q005, Q015, Q025, Q035, Q045) и пять нарушений достаточности контекста (Q055, Q065, Q075, Q085, Q095). Это десять различных запросов; механизм в них общий. Первые показывают физический предел top-5, вторые — неспособность генератора отказаться при потере последней обязательной

части ответа. Существование каждого приведённого `evidence_id` ещё не означает полноты доказательства.

На основном наборе не обнаружено ошибок генератора при наличии всех правильных абзацев. Поэтому пять таких ошибок не придуманы. Для дополнительной проверки создан отдельный `exploratory challenge` из 15 новых случаев: равносильные противоречия, отменённый лимит, цитата сценки, ложная предпосылка, контрфактическое условие, неутверждённый бюджет, отрицания и исключения. Он заморожен после основного эксперимента и до собственных вызовов, оценивается отдельно и не меняет основные 100 вопросов. Это исследовательское дополнение, а не независимый ранее отложенный тест.

В `challenge` из 15 случаев точность полных ответов составила 14/15 (0,933) для `full` и 13/15 (0,867) для `BM25`. Оба режима ошиблись на `CH07`: назвали Антона по реплике учебной сценки, хотя второй абзац ограничивал событие сценкой и указывал отсутствие зарегистрированного реального отключения. Оба абзаца были доступны обоим режимам. Дополнительно `BM25` на `CH14` потерял отзыв разрешения и выбрал шкаф `C-18` вместо `C-29`.

После обнаружения `CH07` отдельно заморожены четыре диагностических варианта цитаты `QR01–QR04`. `Full` ошибся на всех четырёх; `BM25` правильно отказался на `QR01` и ошибся на трёх остальных. Точности этой целенаправленной репликации — 0/4 и 1/4 соответственно; их нельзя считать оценкой обычного потока вопросов. При всех 38 дополнительных запросах `JSON` оставался валидным. Таким образом, получены пять различных фактических `full`-ошибок при наличии правильного контекста, но все они воспроизводят один механизм переноса события из цитаты в действительность.

Во время восьми запросов репликации `GPU` использовался также другой лабораторной. Время дополнительных запросов сохранено для аудита, но не используется для сравнения быстродействия. Флаг `shared_gpu_workload` отмечает репликацию в `CSV`; `timing_comparable=false`



установлен для дополнительных метрик. Таблица времени основного эксперимента относится к отдельному последовательному прогону 200 запросов.

### **1.9 Пятнадцать разобранных ошибок**

1. Q005 / BM25 — Retrieval. Из шести самостоятельных разрешений top-5 вернул только пять. Полного ответа в контексте нет.

2. Q015 / BM25 — Retrieval. Повторяется потеря шестой посылки на другом архиве; проблема в ограничении размера выдачи.

3. Q025 / BM25 — Retrieval. Лексическое сходство позволяет найти тему, но не преодолеть предел пяти абзацев.

4. Q035 / BM25 — Retrieval. Высокий recall 5/6 скрывает невозможность полного ответа на составной запрос.

5. Q045 / BM25 — Retrieval. Даже идеальное ранжирование не поместит шесть обязательных абзацев в пять мест.

6. Q055 / BM25 — Answerable. Модель вернула true и пять разрешений, хотя вопрос требует шесть; нужен отказ по доступному контексту.

7. Q065 / BM25 — Answerable. Структурно валидный частичный ответ ошибочно обозначен достаточным.

8. Q075 / BM25 — Answerable. Все приведённые ссылки существуют, однако полнота запрошенного перечня не проверена.

9. Q085 / BM25 — Answerable. Истинность отдельных пяти значений подменяет наличие полного ответа.

10. Q095 / BM25 — Answerable. Повторяется избыточное решение true при недостающей шестой посылке.

11. CH07 / full — LLM, контекст полный. Назван Антон из сценки; указание на вымышленность и отсутствие реального отключения проигнорировано.

12. QR01 / full — LLM, контекст полный. Названа Анна из реплики об удалении журнала; реальное удаление не зарегистрировано.

13. QR02 / full — LLM, контекст полный. Назван Борис из сценки об открытии шкафа; цитата не доказывает реальное действие.

14. QR03 / full — LLM, контекст полный. Названа Вера из сценки о выносе документов; область действия цитаты утрачена.

15. QR04 / full — LLM, контекст полный. Назван Денис из сценки о сигнализации; наличие имени в тексте ошибочно принято за доказательство события.

Для пяти ошибок LLM эталон — null и answerable=false, поскольку имя исполнителя реального события не установлено. Полные вопросы, исходные фрагменты, фактические ответы и переданные ID опубликованы в results/error\_analysis.md. Первая и вторая пятёрки взяты из разных запросов основного набора; последняя — из отдельно обозначенных диагностических этапов. Никакой ответ модели не исправлялся для получения нужного количества ошибок.

## ЗАКЛЮЧЕНИЕ

На контролируемых коротких регламентах полный контекст обеспечивает полные ответы, а BM25 заметно сокращает вход ценой потери одной обязательной посылки в составных вопросах. Повышать только средний recall недостаточно: нужно контролировать полноту набора доказательств и возможность ответа по переданному материалу. Следующий проверяемый шаг — адаптивное расширение retrieval для составного вопроса либо явная проверка всех запрошенных частей перед выдачей ответа. В этой работе такие изменения не применялись, чтобы сохранить обязательное сравнение full и top-5.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Robertson S., Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond // Foundations and Trends in Information Retrieval. 2009. Vol. 3, no. 4. P. 333–389. DOI: 10.1561/15000000019. URL: [https://www.staff.city.ac.uk/~sbrp622/papers/foundations\\_bm25\\_review.pdf](https://www.staff.city.ac.uk/~sbrp622/papers/foundations_bm25_review.pdf) (дата обращения: 08.09.2026).
2. Pydantic. Strict Mode: официальная документация. URL: [https://pydantic.dev/docs/validation/latest/concepts/strict\\_mode/](https://pydantic.dev/docs/validation/latest/concepts/strict_mode/) (дата обращения: 08.09.2026).
3. LM Studio. Structured Output: официальная документация API. URL: <https://lmstudio.ai/docs/developer/openai-compatible/structured-output> (дата обращения: 08.09.2026).