

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«Национальный исследовательский университет ИТМО»
(Университет ИТМО)

Факультет прикладной информатики
Образовательная программа Мобильные и сетевые технологии
Направление подготовки 09.03.03 Прикладная информатика

О Т Ч Е Т
по лабораторной работе № 6
по дисциплине «Автоматическая обработка текста»

Тема: «AI-детектив»

Обучающиеся: Дущенко Даниил Александрович, К3341
Коваленко Евгений Юрьевич, К3341

Преподаватель: Гусарова Наталия Федоровна

Санкт-Петербург
2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
1 Выполнение работы.....	4
1.1 Методика.....	4
1.2 Проверка и результаты	5
1.3 Обсуждение и ограничения	6
ЗАКЛЮЧЕНИЕ	9
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	10

ВВЕДЕНИЕ

Мы исследовали способность одной локальной LLM находить распределённые основания, применять правило с исключением, сохранять конфликт источников и отказываться от недоказанного ответа. Сюжет полностью вымышленный: два выпуска сборки на турнире «Орион» в период заморозки. Сначала мы сохранили истинную последовательность, затем подготовили девять документов общим объёмом 5046 слов. Скрытый файл истины не передаётся модели.

Досье включает карточку инцидента, журнал доступа, регламент, независимые по сценарию сообщения Ильи и Миры, сообщение и переписку Веры, технический аудит, архив репетиции и план другого турнира. Последние два документа тематически похожи на полезные, но относятся к другим событиям. Мы выделили 36 утверждений с уникальными идентификаторами; каждая доказательная цитата дословно присутствует в источнике. Нарративы содержат организационный фон и пояснения, поэтому набор не моделирует случайную выборку производственных документов.

Мы составили 12 вопросов: по два прямых, многошаговых, временных, на правило с исключением, противоречие и недостаток данных. Статусы означают подтверждение или опровержение пропозиции вопроса, конфликт либо недостаточность оснований. При *contradicted evidence* обосновывает отрицательный ответ; при *both* два списка ориентированы относительно утвердительной пропозиции. Исходные эталоны и варианты зафиксированы хешами до инференса.

1 Выполнение работы

1.1 Методика

Режим А получает все документы и реестр идентификаторов для ссылок. BM25 [1] выбирает для В пятнадцать утверждений. Режим С использует строго тот же набор и те же поля, изменяя группировку и порядок. Общий транспорт LM Studio [3], модель, системный промпт, temperature=0 и seed=42 одинаковы. Ответ проверяется Pydantic [2]; неизвестные ссылки и both без второй стороны отвергаются. Для insufficient требуется null и указание нехватки информации. Эта лексическая проверка не гарантирует истинности свободного объяснения. Сырые ответы, ошибки, токены, время и точный контекст сохраняются; скрытых повторов нет.

Для $p=3$ путь состоит из типа источника, логической категории и временной области. Код равен $a_0+3a_1+9a_2$. Расстояние определяется длиной общего начального префикса, а не разностью кодов; равные пути имеют расстояние ноль. Внутри ветвей записи сортируются по известному времени. Источник поставлен выше времени, чтобы отдельно показать документальные основания, свидетельства и правила. При первом временном уровне соседними стали бы одновременные сообщения разных источников: это могло бы облегчить сравнение конфликтов, но разделило бы связанные нормы и исключения. Альтернативный порядок в эксперименте не проверялся.

Перестановка с seed=42 сохраняет содержание. Удаление одной необходимой посылки применяется к четырём многошаговым/временным вопросам; фрагмент удаляется также из полного документа. Для остальных восьми вопросов этот тест неприменим. Добавление одного подготовленного противоречия выполняется для всех вопросов. В Q11/Q12 конфликт касается осведомлённости Веры, не раскрывая искомый факт: ожидаемый статус остаётся insufficient. Всего предусмотрено 120 измерений.

1.2 Проверка и результаты

Мы выполнили 21 автоматическую проверку, включая все уровни расстояния, ультраметрию на 27³ тройках путей, валидацию, недоступность API, лимит поиска, идентичность В/С и отсутствие удалённого фрагмента. Проверка Streamlit [4] охватила 48 состояний без исключений. До подключения LLM средний recall необходимых утверждений в top-15 по исходным вопросам составил 0,896.

Мы выполнили все 120 запросов; 120 ответов прошли формальную валидацию и завершились stop. Хеши эталонов не изменились, фактические наборы В/С совпали. Израсходовано 688026 входных и 16231 выходной токен; суммарная наблюдаемая задержка составила 1030 с. Это один тёплый прогон, а не оценка холодного старта.

Таблица 1 — Исходные 12 вопросов

Показатель	А	В	С
Ассурасу статуса	0,583	0,583	0,583
Evidence precision	0,500	0,729	0,722
Evidence recall	0,396	0,542	0,604
Evidence F1	0,430	0,604	0,647
Recall контрдоказательств	0,500	1,000	1,000
Precision both	0,250	0,333	0,400
Recall both	0,500	1,000	1,000
Precision insufficient	0,667	1,000	0,667
Recall insufficient	1,000	1,000	1,000
Входные токены, среднее	14221,9	1408,8	1510,5
Выходные токены, среднее	138,8	120,4	129,8
Время запроса, с	15,32	6,33	5,97

Ассурасу измеряет только логический статус. Evidence-метрики усредняются по 12 вопросам; recall контрдоказательств — только по двум вопросам с непустым gold-counterevidence. Invalid-ответов нет. У В/С вход

короче примерно на 90%, но ассурасу статуса осталась той же: 7/12. Рост F1 ссылок не означает автоматически улучшения логического ответа.

Таблица 2 — Стресс-тесты

Показатель	А	В	С
Изменение статуса при перестановке	0,750	0,000	0,000
Стабильность evidence_ids, F1	0,417	1,000	1,000
Ассурасу после перестановки	0,250	0,583	0,583
Ассурасу после удаления, n=4	0,750	0,250	0,000
Ассурасу после противоречия, n=12	1,000	0,917	0,917
Верный переход: удаление, n=4	0,500	0,000	0,000
Верный переход: противоречие, n=8	0,500	0,375	0,250
Уверенные ошибки при нехватке данных, n=10	0,200	0,200	0,200

Верный переход требует правильного статуса и до, и после изменения; для добавления противоречия здесь учитываются восемь вопросов с меняющимся gold. Доля уверенных ошибок считается при $\text{confidence} \geq 0,8$ среди десяти случаев $\text{gold}=\text{insufficient}$ каждого режима во всех вариантах. После перестановки А изменил 9/12 статусов. В/С сохранили статусы и evidence_ids: их контексты при этой перестановке байтово идентичны. Полные таблицы включают также калибровочные интервалы, precision/recall статусов и попарные различия В/С.

1.3 Обсуждение и ограничения

При чтении сохранённых ответов мы выявили три разных границы метрик. Q01/А имеет правильный status=entailed, но неверное время 18:15 вместо 18:12; F1=0 и confidence=1. В Q05/С исходные ссылки C06/C07 и времена верны, F1=1, однако модель ошибочно утверждает, что 18:15

следует после 18:20. После удаления C06 тот же режим подменяет право публикации правом чтения C05, сохраняя confidence=1 и F1=1 по оставшейся эталонной ссылке C07. Напротив, правильный отказ Q05/A после удаления получает F1=0 из-за пустого списка ссылок; его объяснение тоже неточно заявляет нехватку времени первого выпуска, хотя C07 сохранён.

Структура C помогла по метрике статуса в Q12 с добавленным противоречием: insufficient вместо ошибочного both у B. Однако объяснение C спутало искомый архив с архивом репетиции, поэтому это лишь частичный успех. В Q04 с противоречием C проиграл B: проигнорировал доступный C37 и уверенно выбрал entailed вместо both. В Q07 C сослался на условия исключения полнее, чем B, но оба ошибочно противопоставили исключение общему запрету. Таким образом, p-adic упаковка улучшила некоторые ссылки, но не обеспечила правильного применения нормы.

Исходные недостаточные вопросы распознаны всеми режимами, но после удаления посылки правильных отказов осталось 3/4, 1/4 и 0/4. Высокая точность after-contradiction также не равна правильной реакции: для Q07/Q08 модель выбирала both ещё до появления реального конфликта. Confidence не согласуется с достоверностью автоматически: уверенные ошибки соседствуют с confidence=0 у правильных отказов. Шкала не была строго определена как вероятность правильности статуса; калибровочная таблица поэтому является описательной диагностикой.

Оценка evidence использует точные идентификаторы замороженного эталона. Альтернативная корректная ссылка на повторённое разрешение координатора может быть наказана этой метрикой; численная ошибка ссылки не всегда означает ложный смысл. Полные объяснения требуют отдельного чтения. Confidence является самооценкой модели, а не калиброванной вероятностью. Малый набор, один сюжет, один seed и отсутствие повторных выборок не позволяют делать статистические выводы о превосходстве метода вообще.

Мы организовали работу по трём направлениям: досье и эталоны; поиск и p-adic контекст; модель, интерфейс и оценка. При проверке исправили недоказанный вывод об отсутствии права до его выдачи, уточнили роль координатора, временную ветвь очереди и основания конфликтных ответов. Разработку в режиме vibe coding и проверку предложений LLM мы отразили в AI_LOG. Исходники, тесты и сценарий демонстрации сохранены в репозитории.

ЗАКЛЮЧЕНИЕ

На этом досье retrieval сократил вход и время, сохранив accuracy статуса, но изменив характер ошибок. p-adic группировка повысила исходный F1 ссылок, не улучшила accuracy и оказалась слабее после удаления посылки. Полный контекст сильно зависел от порядка документов. Главный результат — воспроизводимое разделение доступности доказательств, выбора ссылок, логического статуса и содержания объяснения; ни один из этих показателей нельзя подменять другим.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- [1] Brown D. rank_bm25: A Collection of BM25 Algorithms in Python. URL: https://github.com/dorianbrown/rank_bm25 (дата обращения: 08.09.2026).
- [2] Pydantic. Models: документация. URL: <https://docs.pydantic.dev/latest/concepts/models/> (дата обращения: 08.09.2026).
- [3] LM Studio. OpenAI Compatibility Endpoints: документация API. URL: <https://lmstudio.ai/docs/developer/openai-compat> (дата обращения: 08.09.2026).
- [4] Streamlit. Documentation. URL: <https://docs.streamlit.io/> (дата обращения: 08.09.2026).